

Обобщение при уточнении понятия замкнутой переменной

А. Н. Непейвода
ИПС им. А.К. Айламазяна РАН

У совместное совещание по языку Рефал

16 июня 2022, МГТУ им. Н.Э. Баумана

Наводящий пример

При обобщении $(\varepsilon)(e.x)$ и $(A)(A\ e.x')$ получается заготовка $(e.x_1)(e.x_1\ e.x_2)$. После чего параметры $e.x_1$ и $e.x_2$ сливаются как подряд идущие, даже если на $e.x$ и $e.x'$ есть рестрикция, запрещающая вхождения буквы A , переносимая на $e.x_2$.

Частичное решение: записать уравнение, устанавливающее связь между переменными после слияния — оказывается слабым, потому что негативные рестрикции всё равно теряются.

Идея

Перенести часть зависимостей из языка рестрикций (уравнения) в язык конфигурации (параметризованное выражение).

Что сейчас:

- Строится кандидат общего вида без обобщений вида $e.i = \varepsilon \mid \varepsilon$.
- Сливаются подряд идущие e-параметры.
- Выбирается наилучший по оценке.

Что хочется:

- Строится кандидат общего вида.
- Если он безопасный \Rightarrow ОК, иначе параметры сливаются, чтобы стал безопасным .
- Выбирается наилучший по оценке.

Идея

Перенести часть зависимостей из языка рестрикций (уравнения) в язык конфигурации (параметризованное выражение).

Что было:

- Строится кандидат общего вида без обобщений вида $e.i = \varepsilon \mid \varepsilon$.
- Сливаются подряд идущие e -параметры.
- Выбирается наилучший по оценке.

Как стало:

- Строится кандидат общего вида.
- Безопасный \Rightarrow ОК, иначе параметры сливаются, чтобы стал безопасным (future work).
- Выбирается наилучший по оценке.

Якорные фрагменты

(пока что в допущении, что t -параметров нет, и без учёта общезначимости дизъюнкции: $e.i = s.i \ e.j \vee e.i = (e.j_1)e.j_2$)

- Константный фрагмент — дерево, не содержащее e -параметров.
- Плоское разбиение — n -ка подвыражений, помечающих узлы в лесе структуры (структурные скобки + вызовы функций) без учёта константных фрагментов.
- Свободный фрагмент — максимальное подвыражение, содержащее только e -параметры.
- Якорный фрагмент — подвыражение плоского разбиения, стоящее между e -параметрами и не содержащее e -параметров.

Язык образца

Базовое семантическое понятие для построения обобщения ассоциативных данных.

Пусть \mathcal{P} — образец; тогда языком $\mathcal{L}(\mathcal{P})$ называется множество всех возможных слов, которые получаются некоторой подстановкой в \mathcal{P} .

Если \mathcal{P}' — обобщение \mathcal{P} , и \mathcal{P} и \mathcal{P}' имеют одну и ту же структуру леса над плоским разбиением, то $\mathcal{L}(\mathcal{P}) \subseteq \mathcal{L}(\mathcal{P}')$ (как образцов, полученных из параметризованных выражений).

Возможные проблемы

Что плохое может случиться, если мы перестанем сливать соседние параметры?

Перестаёт выполняться критерий обрыва цепи вычислений (нарушается свойство wqo).

- • Крускал + Турчин \Rightarrow безопасно (Крускал выполняется всегда, а Турчин не смотрит на параметры).

Возможные проблемы

Что плохое может случиться, если мы перестанем сливать соседние параметры?

Перестает выполняться критерий обрыва цепи вычислений (нарушается свойство wqo).

- • Крускал + Турчин \Rightarrow безопасно (Крускал выполняется всегда, а Турчин не смотрит на параметры).

Последовательность обобщений становится бесконечной (нарушается свойство нётеровости).

- • Опасно!

$$P_1 = e.x_0e.x_0$$

$$P_2 = e.x_1e.x_0e.x_0e.x_1$$

$$P_3 = e.x_2e.x_1e.x_0e.x_0e.x_1e.x_2$$

Открытые переменные

Рассмотрим произвольный образец P .

- Семантически открытая e -переменная — такая переменная $e.i$, что при сопоставлении вида $P, e.i : \text{Cond}$ могут потребоваться рекурсивные возвраты (расширения).
- Синтаксически открытая e -переменная — переменная, входящая в некоторый элемент плоского разбиения P вместе с какой-нибудь другой e -переменной.

Совпадают ли эти понятия?

Синтаксис vs семантика

Рассмотрим образец $(e.x_1 e.x_2) e.x_2 e.x_1 e.x_1$. Он однозначный (т.е. существует единственная возможная подстановка), но в нём нет ни одной синтаксически замкнутой переменной.

- Проводим разбиение на равносоставленные фрагменты, отчего длина $e.x_1$ определяется однозначно.

Рассмотрим образец $(e.x_1 e.x_2)(e.x_2 e.x_3)(e.x_3 e.x_1)$. Он однозначный, но в элементах его плоского разбиения нет равносоставленных префиксов или суффиксов.

- Сравнение длин двух решений приводит к противоречию.

n -замкнутость

Пусть \mathcal{P} — образец (выражение); P_1, \dots, P_n — свободные фрагменты элементов его плоского разбиения (далее кратко СФР).

- Если $e.j$ — единственная e -переменная, входящая в некоторый P_k , тогда $e.j$ — 0-замкнутая.
- Если $e.j_1, \dots, e.j_k$ — j_i -замкнутые переменные, входящие в P_k вместе с некоторой $e.j_{k+1}$, степень замкнутости которой неизвестна либо больше $\max(j_i) + 1$, тогда $e.j_{k+1}$ — $\max(j_i) + 1$ -замкнутая.

Утверждение

Если все переменные образца \mathcal{P} i -замкнутые, тогда степень замкнутости переменной, входящей в его СФР P_1, \dots, P_n , не может превышать $n - 1$.

Мера открытости

Дан СФР P . n -ку (t_{n-1}, \dots, t_0) такую, что t_i — количество различных переменных замкнутости i , входящих в P , назовём мерой открытости $\mu(P)$.

В образце $(e.1\ e.1)(e.2)(e.1\ e.2)$ все переменные являются 0-замкнутыми (вычисляются однозначно), но меры открытости его СФР $(P_1, P_2, P_3) = (e.1\ e.1, e.2, e.1\ e.2)$ различны. $\mu(P_1) = \mu(P_2) = (0, 0, 1)$, $\mu(P_3) = (0, 0, 2)$

Мера открытости

Дан СФР P . n -ку (t_{n-1}, \dots, t_0) такую, что t_i — количество различных переменных замкнутости i , входящих в P , назовём мерой открытости $\mu(P)$.

В образце $(e.1\ e.1)(e.2)(e.1\ e.2)$ все переменные являются 0-замкнутыми (вычисляются однозначно), но меры открытости его СФР $(P_1, P_2, P_3) = (e.1\ e.1, e.2, e.1\ e.2)$ различны. $\mu(P_1) = \mu(P_2) = (0, 0, 1)$, $\mu(P_3) = (0, 0, 2)$

Утверждение

Если в СФР i -замкнутого образца добавляется e -переменная, которая туда не входит (но может входить в другие СФР того же образца), то мера открытости этого СФР может только увеличиться лексикографически.

Различающая подстановка

Пусть Φ_i — константные фрагменты элементов плоского образца P . Рассмотрим различные $\Psi_i \in (\Sigma^*)$ такие, что $\forall i, j (\Psi_i \neq \Phi_j)$ (таких Ψ_i можно построить неограниченное количество). Пусть $e.i$ — e -переменные, входящие в P . Назовём подстановку σ такую, что $\sigma(e.i) = \Psi_i$, различающей подстановкой.

Утверждение

Пусть (P_1, \dots, P_n) — кортеж СФР k -замкнутого образца \mathcal{P} . Построим образец \mathcal{P}' добавлением в некоторые P_i ещё одного вхождения какой-либо переменной, уже входящей в P_i . Тогда $\mathcal{L}(\mathcal{P}) \not\subseteq \mathcal{L}(\mathcal{P}')$.

Оставшийся случай

Набор переменных в P_i остался тот же, при этом кратность некоторых из них увеличилась, а других — уменьшилась. Может ли такое преобразование (как минимум) сохранять язык образца?

- По индукции: для СФР, имеющих $\mu(P) = (0, \dots, 0, 1)$, такое невозможно из-за существования различающей подстановки. Следовательно, невозможно для P с $\mu(P) = (0, \dots, 0, n)$.
- Предположим, что для всех СФР, имеющих $\mu(P) = (0, \dots, 0, t_i, \dots)$, такое невозможно. Тогда для СФР, имеющих $\mu(P) = (0, \dots, 1, t_i, \dots)$, это также невозможно, поскольку значения всех прочих переменных после различающей подстановки фиксированы.

Нётеровость обобщений

Набросок теоремы

Если k_i -замкнутый образец обобщается до k_j -замкнутого, тогда выполняется минимум одно условие (в порядке приоритетов):

- уменьшается число элементов плоского разбиения или СФР;
- увеличивается общее число различных переменных (ограниченное сверху числом СФР);
- увеличивается мера открытости СФР (также ограничена сверху);
- при сохранении двух предыдущих мер — уменьшается кратность некоторой переменной.

Future Work

- Точный критерий семантической замкнутости переменной либо доказательство алгоритмической неразрешимости задачи проверки семантической замкнутости (и поиск различных эвристик, аппроксимирующих её снизу).
- Модификация алгоритмов сопоставления с образцом с учётом расширенного понятия замкнутости.
- Совершенствование алгоритма приведения обобщённого выражения к «безопасной» форме.

Future Work

- Точный критерий семантической замкнутости переменной либо доказательство алгоритмической неразрешимости задачи проверки семантической замкнутости (и поиск различных эвристик, аппроксимирующих её снизу).
- Модификация алгоритмов сопоставления с образцом с учётом расширенного понятия замкнутости.
- Совершенствование алгоритма приведения обобщённого выражения к «безопасной» форме.

Спасибо за внимание!