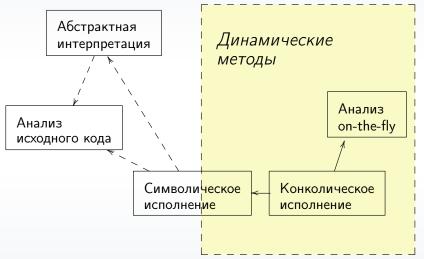


Индуктивный динамический анализ программ

Летняя практика, Переславль-Залесский 4–8 июля 2022 г.



Статический vs. динамический





Абстрактная интерпретация

 Основа метода — факторизация области определения программы с помощью введения гомоморфизма на данных.

Операция ++ — ассоциативная конкатенация, множество данных — строки.

$$f(x, x ++ y) = x ++ 'A' ++ f(x,y)$$

 $f(x, /* пустое слово */) = 'A'$

- Если факторизовать данные так: $\sigma(x)=t_1\Leftrightarrow x\in A^*$, $\sigma(x)=t_2\Leftrightarrow \neg(x\in A^*)$, то очевидно, программа тривиализуется до f(x,x)=x.
- Факторизация $\sigma(x) = t_1 \Leftrightarrow x \in A^*$, $\sigma(x) = t_2 \Leftrightarrow x \in B^*$, $\sigma(x) = t_3 \Leftrightarrow (x \notin A^* \& x \notin B^*)$ некорректна из-за перекрытия прообразов абстрактных значений t_1 и t_2 .



Символическая интерпретация

 Основа метода — замена конкретных данных на параметры и анализ возможных путей выполнения при конкретизации этих параметров.

- Если вычисляется самый внешний вызов (нормальный порядок вычислений, call-by-name), символическая интерпретация доказывает, что False-ветка недостижима из init(x) для всех значений x.
- Плюс: не нужно под каждую задачу строить свой гомоморфизм; минус слишком общий.



Конколическая интерпретация

 Исполнение на конкретных данных как на символических, с обратным просчётом по путям для порождения наиболее полного накрытия тестами.

```
f('A' ++ x) = f(x)
f(/* пустое слово */) = 'True'
f('Такого теста не будет') = 'AXAXA'
f(_ ++ x) = 'False'
```

- При конколическом запуске f('AAA') на первом же ветвлении будут построены тесты f(/* пустое слово */), f('BAA') (или другая первая буква, но не 'A') и f('Takoro теста не будет').
- Требует уже реализованного механизма символической интерпретации и механизма восстановления исходных данных (часто — с привлечением SMT-солверов).



- Строится накрытие (чаще) либо подмножество реальных путей исполнения программы.
- По «индукции» строится структура, отражающая некоторые свойства программы.

Индукция здесь инверсна порядку выполнения. Такая обращённая схема индукции иногда называется «коиндукция».



- Строится накрытие (чаще) либо подмножество реальных путей исполнения программы.
- По «индукции» строится структура, отражающая некоторые свойства программы.

Индукция здесь инверсна порядку выполнения. Такая обращённая схема индукции иногда называется «коиндукция».

• База — терминальные (конечные) состояния.



- Строится накрытие (чаще) либо подмножество реальных путей исполнения программы.
- По «индукции» строится структура, отражающая некоторые свойства программы.
- База терминальные (конечные) состояния.
- Шаг (от n + n k) ??? Должен отражать закономерность, а не просто быть переходом к следующему вычислительному состоянию.



- Строится накрытие (чаще) либо подмножество реальных путей исполнения программы.
- По «индукции» строится структура, отражающая некоторые свойства программы.
- База терминальные (конечные) состояния.
- Шаг (от n + n k) ??? Должен отражать закономерность, а не просто быть переходом к следующему вычислительному состоянию.
- Индуктивный переход (метод сведения к предыдущему случаю) ??? Как понять, что пути вычислений повторяют уже исследованные?



Порождение путей вычислений

- Дано: абстрактное (символическое, псевдосимволическое) состояние.
- Построить: множество достижимых из него состояний (при той же разметке или факторизации).

Императивный случай

- Рассматривается control-flow-graph.
- По графу строится множество состояний, за шаг достижимых из данного.

Функциональный случай

- Состояние унифицируется с определениями.
- Строится множество результатов применения правил переписывания.



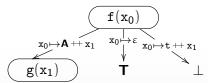
$$\begin{array}{ll} \textbf{f}(\textbf{A} +\!\!+ \textbf{x}) = \textbf{g}(\textbf{x}) & \textbf{g}(\textbf{B} +\!\!+ \textbf{x}) = \textbf{f}(\textbf{x}) \\ \textbf{f}(\textbf{\epsilon}) = \textbf{T} & \textbf{g}(_) = \bot \\ \textbf{f}(\textbf{t} +\!\!+ \textbf{x}) = \bot & \end{array}$$

Здесь \bot — это аналог состояния «ошибка», приводящий к исключению. Семантика сопоставления — стандартная, сверху вниз. Операция ++ — операция конкатенации, которая в этом примере может быть заменена и на обычный солз. Знак _, как обычно при сопоставлении с образцом (например, в Python и в Haskell), означает произвольное значение. Также это правило можно записать в форме $g(x) = \bot$, однако использование _ подчёркивает, что этот элемент образца не используется в правой части.



$$\begin{array}{ll} \textbf{f}(\textbf{A} +\!\!+ \textbf{x}) = \textbf{g}(\textbf{x}) & \textbf{g}(\textbf{B} +\!\!+ \textbf{x}) = \textbf{f}(\textbf{x}) \\ \textbf{f}(\epsilon) = \textbf{T} & \textbf{g}(_) = \bot \\ \textbf{f}(\textbf{t} +\!\!+ \textbf{x}) = \bot & \end{array}$$

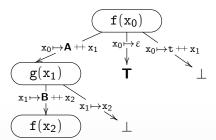
Обратим внимание на очерёдность сиблингов в графе: подстановка $x_0 \mapsto \mathbf{A} + x_1$ приоритетнее, чем $x_0 \mapsto \mathbf{t} + x_1$, поскольку находится левее.



По подстановкам $x_0 \mapsto \epsilon$ и $x_0 \mapsto t + x_1$ мы дошли до базы индукции (терминальных состояний). Но в узле $g(x_1)$ шаг индукции делать рано: вызов на вершине стека другой.



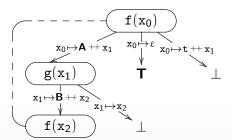
$$\begin{array}{ll} \textbf{f}(\textbf{A} +\!\!+ \textbf{x}) = \textbf{g}(\textbf{x}) & \textbf{g}(\textbf{B} +\!\!+ \textbf{x}) = \textbf{f}(\textbf{x}) \\ \textbf{f}(\epsilon) = \textbf{T} & \textbf{g}(_) = \bot \\ \textbf{f}(\textbf{t} +\!\!+ \textbf{x}) = \bot & \end{array}$$



А вот теперь пришло время сделать переход от $f(x_2)$ к $f(x_0)$. Заметим, что состояние $f(x_0)$ формально «старше», т.к. получается из $f(x_2)$ за два шага вычислений.



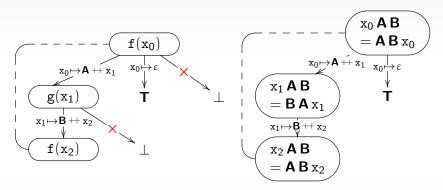
$$\begin{array}{ll} \texttt{f}(\textbf{A} +\!\!+ \texttt{x}) = \texttt{g}(\texttt{x}) & \texttt{g}(\textbf{B} +\!\!+ \texttt{x}) = \texttt{f}(\texttt{x}) \\ \texttt{f}(\epsilon) = \textbf{T} & \texttt{g}(_) = \bot \\ \texttt{f}(\texttt{t} +\!\!+ \texttt{x}) = \bot & \end{array}$$



Развёртка путей вычисления замкнулась: полученный граф в точности описывает все такие пути (поскольку переход был сделан простой переименовкой x_2 в x_0).



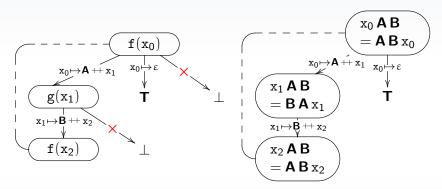
(Ко)индукция повсюду



Справа — схема решения уравнения в словах. Если стереть метки узлов и не обращать внимание на пути вычислений, приводящие к исключениям, обе схемы идентичны.



(Ко)индукция повсюду



Справа — схема решения уравнения в словах. Можно сказать, что метод Матиясевича решения уравнений выполняет их символическую интерпретацию в DSL уравнений в словах.



Когда пора остановиться?

 Слишком рано — не удастся сделать индуктивный переход.

Пример: попытка возврата по переходу от $f(x_0)$ до $g(x_1)$.

Слишком поздно — экспоненциальный взрыв путей вычисления.

Пример: добавочный переход от $f(x_2)$ к $g(x_3)$ по ветке $x_2 \mapsto \mathbf{A} + + x_3$ (с порождением ещё двух переходов).

• Главное — когда-нибудь остановиться вообще.



Когда пора остановиться?

• Слишком рано — не удастся сделать индуктивный переход.

Пример: попытка возврата по переходу от $f(x_0)$ до $g(x_1)$.

Слишком поздно — экспоненциальный взрыв путей вычисления.

Пример: добавочный переход от $f(x_2)$ к $g(x_3)$ по ветке $x_2 \mapsto \mathbf{A} + + x_3$ (с порождением ещё двух переходов).

• Главное — когда-нибудь остановиться вообще.

Частичный порядок \preceq есть Well-Quasi-Order (хороший предпорядок) на множестве \mathcal{M} , если для любой бесконечной последовательности $\{C_i\}$ элементов из \mathcal{M} $\exists k_1, k_2(k_1 < k_2 \ \& \ C_{k_1} \preceq C_{k_2}).$



Когда пора остановиться?



Частичный порядок \leq есть Well-Quasi-Order (хороший предпорядок) на множестве \mathcal{M} , если для любой бесконечной последовательности $\{C_i\}$ элементов из \mathcal{M} $\exists k_1, k_2 (k_1 < k_2 \& C_{k_1} \preceq C_{k_2}).$

- «Похожие» не значит «одинаковые».
- WQO не обязан быть «QO» (может нарушаться транзитивность) и не обязан быть «W» на всём \mathcal{M} (достаточно на последовательностях элементов из \mathcal{M} , которые могут порождаться программой).



Индуктивный переход





Состояние C_{k_2} вкладывается в состояние C_{k_1} графа вычислений программы, если все пути вычислений, порождаемые C_{k_2} , могут порождаться также и C_{k_1} .

Если заштрихованная часть пуста, то вложение точное: то есть индуктивный переход порождает описание множества путей из $C_{\mathbf{k}_2}$ в терминах путей из $C_{\mathbf{k}_1}$ без потери информации. В частности, точными являются переходы, требующие только переименовки параметров.



Индуктивный переход





Состояние C_{k_2} вкладывается в состояние C_{k_1} графа вычислений программы, если все пути вычислений, порождаемые C_{k_2} , могут порождаться также и C_{k_1} .

В общем случае нельзя ожидать не только точных индуктивных переходов, но и просто вложений.

При анализе путей из $f(x_0,\,\epsilon)$ при развёртке по правилам:

$$\mathtt{f}(\boldsymbol{A} +\!\!\!+ \mathtt{x},\, \mathtt{y}) = \mathtt{g}(\mathtt{x},\, \mathtt{y} +\!\!\!+ \boldsymbol{B}) \hspace{1cm} \mathtt{f}(\epsilon,\, \mathtt{y}) = \mathtt{g}(\boldsymbol{A} +\!\!\!+ \mathtt{y})$$

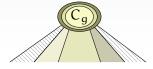
появится набор состояний вида $f(x_i, \mathbf{B^i})$. Каждое из этих состояний порождает дочернее состояние вида $g(\mathbf{AB^i})$, не являющееся дочерним ни для какого другого.



Индуктивный переход







Состояние C_g является обобщением состояний C_{k_1} и C_{k_2} графа вычислений программы, если все пути вычислений, порождаемые C_{k_1} и C_{k_2} , могут порождаться также и C_g .

Чем меньше заштрихованная часть, тем меньше потеря информации при обобщении. Точное обобщение (с нулевой такой частью) построить не удаётся почти ни в каком случае.



Вложение и обобщение состояний

На практике отношение вложения путей, порождаемых состояниями, не разрешимо (не существует алгоритма, который его определяет). Поэтому используются приближённые отношения.

Состояние C_{k_2} вкладывается в состояние C_{k_1} графа вычислений программы, если существует подстановка σ такая, что $C_{k_1}\sigma=C_{k_2}$.

Состояние C_g является обобщением состояний C_{k_1} и C_{k_2} графа вычислений программы, если существуют подстановки σ_1 и σ_2 такие, что $C_g\sigma_1=C_{k_1}$, $C_g\sigma_2=C_{k_2}$.

- Синтаксические
- Легко верифицируемые



Нётеровость

- Множество путей, порождаемых обобщённым состоянием, включает в себя множества путей обобщаемых состояний. Т.е. определяется возрастание $C_{\mathbf{k}_i} \leq C_g$ по вложению.
- Нет гарантии, что возрастающая последовательность $C_{g_1} \unlhd C_{g_2} \unlhd \cdots \unlhd C_{g_i} \unlhd \ldots$ когда-нибудь стабилизируется.

В алгебрах, содержащих ассоциативные операции, существуют

бесконечные возрастающие последовательности, не обладающие нётеровостью, например: $f(x_0\,x_0),\,f(x_1\,x_0\,x_0\,x_1),\,\ldots,\,f(x_{k+1}\,x_k\,\ldots\,x_0\,x_0\,\ldots\,x_k\,x_{k+1}),\,\ldots$ Над данными в свободной алгебре (древесными термами) таких последовательностей не существует, если возрастание $T_i \unlhd T_j$ определяется наличием подстановки σ такой, что $T_i\sigma = T_i$.



Нётеровость

• Нет гарантии, что возрастающая последовательность $C_{g_1} \unlhd C_{g_2} \unlhd \cdots \unlhd C_{g_i} \unlhd \ldots$ когда-нибудь стабилизируется.

Алгоритм обобщения корректен, если порождаемые им состояния являются нётеровыми относительно отношения вложения путей. Свойство нётеровости гарантирует, что вместо обобщения рано или поздно выполнится вложение.

Эквивалентно артиновости (фундированности, Well-Founded-Ordering) обратного отношения (C_{k_i} к C_g).



Алгоритм обобщения корректен, если порождаемые им состояния являются нётеровыми относительно отношения вложения путей. Свойство нётеровости гарантирует, что вместо обобщения рано или поздно выполнится вложение.

Эквивалентно артиновости (фундированности, Well-Founded-Ordering) обратного отношения (C_{k_i} к C_q).

Два кита индуктивного динамического анализа:

- WQO (шаг);
- WFO (индуктивный переход).